Big Data Analytics Programming

Week-11. Review

Jungwon Seo, 2021-Fall

1. 변수

파이썬에서의 변수

변수란?

- 변수 (Variable)
  - 메모리에 값을 저장하기 위한 명명된 위치
- Scalar 형태와 Collection형태로 나눌 수 있음
  - 단일 값은 갖는 Scalar 형태
  - 복수의 값들을 갖을 수 있는 Collection 형태
  - Collection형태는 자료구조(Data Structure)로도 불림

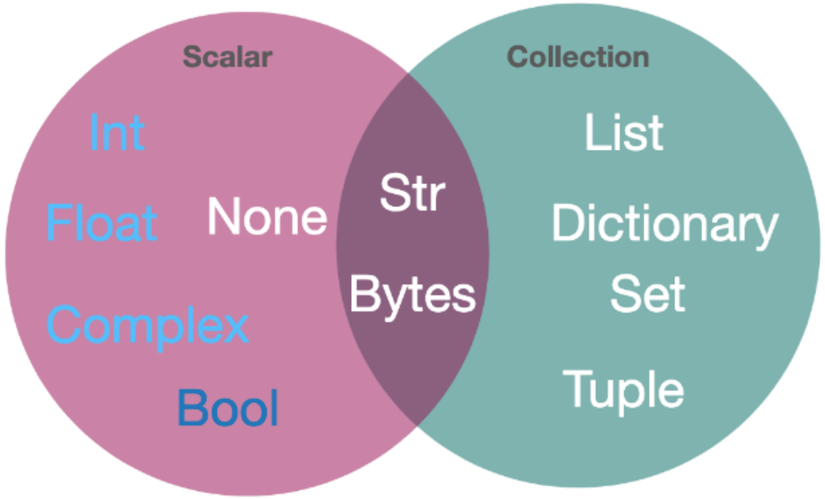

파이썬에서의 변수
숫자형 변수

- 숫자형 변수의 연산들
  - +, -, *, /: 사칙연산
  - ** : 지수연산, ====> root == **0.5
  - % : 나머지 구하기, 5%3 ===> 2
  - //: 몫 구하기, 10//3 ==> 3
- 숫자형 변수간의 형변환
  - int(a), float(a), bool(a) 와 같은 식으로 casting 함수를 적용
  - 형변환 없이 연산 적용시, 상위 형으로 자동 변형
    - 나누기의 경우 int, int 연산이여도 float으로 자동변형

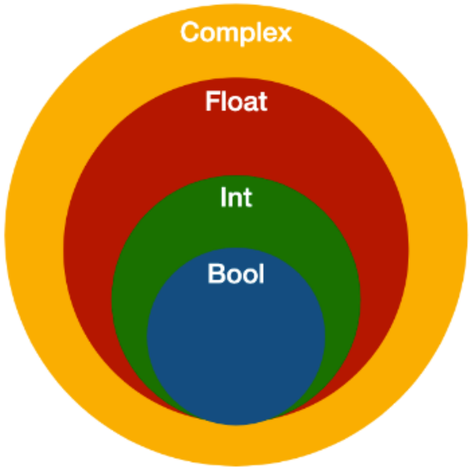

2. 자료구조

자료구조

문자열 String

- 문자열
  - 쌍따옴표(") 또는 따옴표(')로 감싸진 값
- 문자열의 특징
  - 대소문자가 다르게 인식된다: 'A' != 'a'
  - 숫자 1과 문자열 1은 다르다: 1 != '1'
  - + 연산자는 두 string을 연결하는 역할을 한다: 'he' + 'llo' = 'hello'
  - 문자열간의 *,-,/ 연산자는 지원되지 않는다.
  - 문자열 * 숫자는 해당 문자를 숫자만큼 생성한다: 'a'*5 = 'aaaaa'
  - **인덱스로 각각의 문자를 접근할 수 있다: 'hello'[3] => 'L'**

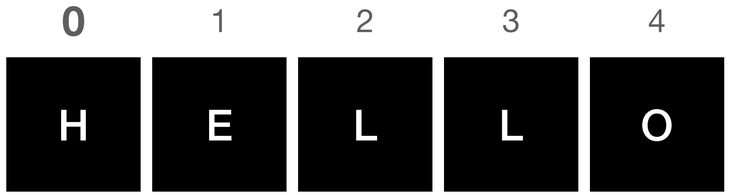

자료구조
또는 Collection 타입

- 복수의 값들을 저장하기 위한 자료구조들
- **List**
  - [ ] 로 감싸지고, 각각의 값은 쉼표로 구분: [1,2,3,4,5,6,7]
  - 인덱스로 접근
- **Dictionary**
  - { }로 감싸지고, key-value 형태가 ':' 기준으로 표현: {"Tom":100, "Tony": 20}
  - Key로 접근
- **Set**
  - { }로 감싸지고, 각각의 값은 쉼표로 구분: {1,2,3}==> unqiue한 원소를 리스트에서 뽑을때
  - 중복된 값을 허용하지 않음, for 문과 같은 반복자로 접근 해야함
- Tuple
  - ( )로 감싸지고, 각각의 값은 쉼표로 구분: (1,2,3,4)
  - 인덱스로 접근, 수정 불가

자료구조

List

- Create
  - **my_list = [ ]** 또는 **my_list = list( )**, 만약 초기값(initial value)를 제공한다면, **my_list = [1,2,3]**
- Read
  - list 전체에 대한 접근은 list 명 그대로: **print(my_list), temp_list = my_list**
  - 원소에 대한 접근은: **my_list[*index*]**, 이때 index는 해당 원소의 위치 (0부터 시작, 정수)
  - 예) **a = [1, 2, 3, 4]** 일 때 **a[4] => ?? Index Error**
- Update
  - list 전체를 변경하는 경우는 변수 재할당 : **my_list = ['a','b','c']**
  - 원소에 대한 변경은: **my_list[*index*] = 'k'**
  - 원소 추가는: **my_list.append('x')**
  - Concatenation은 : **[1,2,3] + ['a','b','c'] => [1, 2, 3, 'a', 'b', 'c']**
- Delete
  - list 전체에 대한 delete는: **del my_list**
  - n번째 원소에 대한 delete는 : **del my_list[*n*]**

자료구조

List

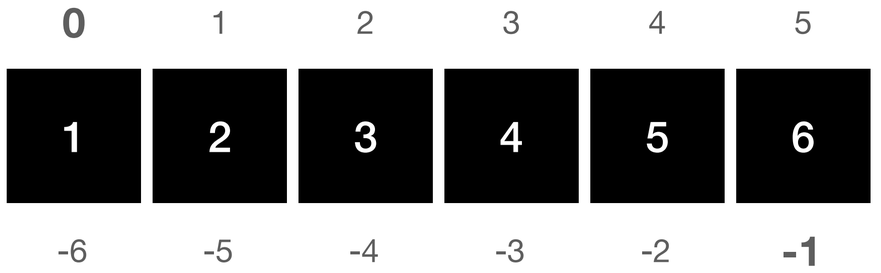

- Python의 List의 경우에는 Subset에 접근 가능
  - 예) **a = [1,2,3,4,5,6]** 일때 앞에 3개만 추출 하려는 경우?
- list[start:end]
  - start는 시작하려는 index, end는 마지막의 다음 index
  - **a = [1,2,3,4,5,6]** 일때, **a[0:3]**은 0,1,2 index에 대한 접근 => **[1,2,3]**
  - 만약 start 부분 또는 end 부분을 생략한다면, **list[1:] == list [0 : len(list)]**
- list[-start:-end]
  - 음수의 index를 넣는 경우, "뒤에서부터 n번째"의 의미
  - 예) a[-1]는 맨 뒤의 원소, a[-3]은 뒤에서 세번째 원소
  - 예) a[1:-3]은? => [2,3]

자료구조

Dictionary

- Create
  - **my_dict = { }** 또는 **my_dict = dict( )**, 만약 초기값(initial key-value)를 제공한다면, **my_dict = { 'a':1 }**
- Read
  - dictionary 전체에 대한 접근은 dictionary 명 그대로: **print(my_dict), temp_dict = my_dict**
  - Value에 대한 접근은: **my_dict[*key*]**, 이때 key는 dictionary를 정의 할 때 사용한 Key
- Update
  - dictionary 전체를 변경하는 경우는 변수 재할당 : **my_dict = { "a": 3 }**
  - Value에 대한 변경은: **my_dict[*key*] = *value***
  - Key-Value 추가: **my_dict[*new_key*] = *value***
- Delete
  - dictionary 전체에 대한 delete는: **del my_dict**
  - Key에 대한 delete는 : **del my_list[*key*]**
    - 이때, Mapping 된 Value도 같이 소멸

자료구조

Dictionary

- Dictionary의 전체 데이터에 대한 접근은 크게 세가지
- 전체 Key 출력
  - my_dict.keys( )
  - 출력: dict_keys(['name', 'age', 'height', 'retired']) =>list처럼
- 전체 Value 출력
  - my_dict.values( )
  - 출력: dict_values(['손흥민', 29, 183, False]) =>list 처럼
- 전체 Item 출력
  - my_dict.items( )
  - 출력: dict_items([('name', '손흥민'), ('age', 29), ('height', 183), ('retired', False)])

4. 조건문과 반복문

조건문과 반복문
조건문

- **if**, **elif**, **else**의 키워드로 조건이 만족하는 상황에서만 하위 코드를 실행
- 조건은 True 또는 False 형태로 나오는 값 또는 연산
  - Else는 뒤에 조건이 없음

Team True!! 👻	Team False!! 👽
True	False 0 0.0
All numbers except 0	
All collections except collection **with no element**	None [ ] ( ) "" { }
~~All functions~~	

```
score = -5
if score >= 100:
    score = 100
elif score <= 0 :
    score = 0
```

```
score = 70
grade = None
if score >= 50:
    grade = "Pass"
else:
    grade = "Fail"
```

조건문과 반복문

반복문

- 반복문 while
  - 특정 조건을 만족하는 한 하위 코드를 반복해서 실행
- 반복문 for
  - Collection 타입의 데이터의 내부 원소 개수 만큼 반복분을 실행
- 반복문 제어
  - Break: 반복문 종료
  - Continue: 현재 지점까지만 실행하고 다음 턴으로 넘김

```
budget = 100
while budget > 0 :
    budget -= buy()
print("No more money")
```

```
my_list = ['a','b','c']
for ele in my_list:
    print(ele)
```

```
for i in range(0,10):
    print(i)
```

5. 함수와 클래스

함수와 클래스

함수 function

- 코드의 가독성 및 효율 성을 높이기 위해, 특정한 연산들을 한 곳에 모아둔 문법
- 구성요소
  - 함수 이름
  - 함수 파라미터 (optional)
  - 함수 내부 연산
  - 함수 반환 값 (optional) : return x
- 주의 할 점
  - 함수 내부에서의 변수와 함수 외부에서의 변수는 동작하는 영역이 다름
  - 함수 내부에서, 함수 외부 값을 변형하기 위해서는 : global 키워드 사용

```
def outer_func(a):
    x = 10
    def inner_func():
        x = 3
        print(x)
    inner_func()
    print(x)

x = 5
outer_func()
print(x)
```

함수와 클래스

클래스 Class

- 변수가 상태, 함수가 행동을 표현한다면, 클래스는 둘 다
- class의 구성요소
  - method/function: 클래스 내에 있는 함수
  - attribute/variable: 클래스 내에 있는 변수
  - 생성자
    - 최초 클래스를 인스턴스화 할때 실행되는 부분
    - __init__
  - 부모클래스
    - 클래스 이름 오른쪽에 괄호와 함께 제공이되는 클래스

```
class Mammal:
    def __init__(self):
        pass


class Human(Mammal):
    def __init__(self,date_of_birth, name, nationality):
        self.date_of_birth=date_of_birth
        self.name = name
        self.nationality = nationality
    def think(self):
        pass
    def move(self):
        pass

jungwon = Human("900302", "서중원", "대한민국")
```

6. 데이터

데이터

데이터 수집

- 파일 읽기관련 함수 및 라이브러리
  - 일반 텍스트 파일: open
  - JSON 파일: json 라이브러리
  - CSV: Pandas
  - HTML: beautifulsoup
- 네트워크 통신을 통한 파일 읽기
  - requests 라이브러리
  - 데이터베이스의 경우 해당 데이터 베이스와 관련된 라이브러리: 예) mysql connector

데이터
크롤링

- 웹사이트에 있는 정보를 프로그래밍 적으로 수집하는 과정
- Python을 이용한 크롤링
  - 여러 방법이 있지만, requests를 이용한 해당 웹사이트 호출 후 내용 파싱(parsing)
  - 정적 웹사이트: 주소(URL) 그대로 입력을 해서 가져오면 웹사이트에서 보이는 콘텐츠가 그대로 가져와지는 경우
  - 동적 웹사이트: 주소(URL)를 기반으로 requests를 통해 가져온 결과와 웹사이트에서 보여지는 결과가 다른경우
    - 추가적인 URL을 찾아야 함: 크롬 개발자도구
    - header값을 조작하여, 인증 및 기타 보안 관련 장애물들을 우회

7. 데이터 전처리

데이터 전처리
데이터 종류별 전처리 방법

- 텍스트 데이터 전처리
  - 원형복원, 고빈출/저빈출어 제거, 불용어 제거
- 이미지 데이터 전처리
  - 리사이즈: 가로, 세로, 채널, Cropping
- 테이블 형태 데이터 전처리
  - 결측값 제거: 채우거나(평균, 중위값, 또다른 학습에 의해), 행이다 열을 제거하거나
  - Noise, Outlier 제거
  - 숫자형 데이터: 정규화 (min-max 스케일링) ===> 0~100 => 0~1
  - 범주형 데이터: 인코딩 (one-hot 인코딩) =====> 혈액형 -> [0,0,0,1], [0,0,1,0], [0,1,0,0], [1,0,0,0]
  - 순서가 있는 범주형: A, B, C,D, F ===> 5,4,3,2,1

8. EDA

탐색적 데이터 분석
데이터 파악을 위한 분석

- 시각적/수치적 요약 데이터로 전체 데이터를 다양한 각도로 분석
- 요약 통계
  - 수치형 데이터: 평균, 최대, 최소, 중위값, 분산, 표준편차
  - 명목형 데이터: 최빈값, 빈도수
- 시각화
  - 다양한 차트를 이용

EDA
상관관계 분석

- 상관관계 분석
  - 특성간의 상관관계를 비교하여 특성들간의 관계를 수치화한다
    - 상관관계의 범위 -1.0~1.0
    - 양의 상관관계: 한 값이 증가하면 다른 값도 증가
    - 음의 상관관계: 한 값이 증가하면 다른 값은 감소
  - 단, 높은 상관관계를 보인다고 해서 반드시 추후 모델 학습에서 더 좋은 성능을 보장하는 것은 아님

E.O.D